同一批财报：什么问题该建库，什么问题该微调

方向 A · 白酒 15 家上市公司 2025 年报问答知识库 | 2,698 页 / 3,988 张表格 / 9,762 个文本块（每块带公司 · 章节 · 页码） | 本地 BM25 + bge-small-zh 向量混合检索 | 线上 Vercel 纯静态版（检索在浏览器里跑，无后端） | 15 道题逐题记录 + 6 道失败题 × 5 种召回策略对照

9/15	9 / 9	0 / 3
检索可答（严格口径） 另有 1 题属碰巧命中，不计入	单公司 · 要一个数字 最好第 1 位命中，出处精确到页码	跨公司 · 全景（无候选集） top-8 最多覆盖 8/15 家，结构上就答不了

一、哪类题答得好，哪类题翻车，为什么 判据：标准答案需要的证据（哪家公司 + 哪个数字）有没有进 top-8

题型分组	题数		结果	为什么
① 单公司 · 一个数字	9		9/9	答案就是原文里的一行，语义检索直接命中；9 题全部召回，8 题 gold 块排进前 8，还能给出「公司 + 页码」出处，可审计
② 跨公司 · 全景（无候选集）	3		0/3	要扫完全部 15 家再取极值，而 top-8 只有 8 个名额、最多覆盖 8 家公司——结构上就覆盖不全，不是排序不够好
③ 跨公司 · 受限（给了候选集）	2		0/2	点名了公司也会被「最像问句的那一两家的块」挤掉名额：Q10 点名两家，top-8 只覆盖 1/15 家，top-40 也只有 2 家
④ 单公司 · 要拼多块	1		0/1	要 3 个数字（营收 / 净利 / 毛利率），top-8 被同一章节的块占满，只召回 1 个

答得好的题：长什么样，为什么对

长什么样：点名了公司，要一个具体数字或事实。

例子：贵州茅台营业收入多少 / 五粮液归母净利润多少 / 洋河股份年末经销商几家 / 茅台在职员工多少人 / 审计意见类型。

为什么对：答案是原文里的一行，问句和那一行在字面上几乎重合，BM25 与向量都直接命中；9 题里 8 题 gold 块排进前 8，最好第 1 位。

结论：这类题建库就有用，不需要微调。

翻车的题：长什么样，为什么错

长什么样：要么「15 家里谁最……」，要么「同一家公司给我三个数」。

例子：谁营收增速最快 / 谁亏损 / 谁毛利率最高 / 茅台营收+净利+毛利率。

为什么错：检索按相似度取 8 块，天生做不了全集扫描与极值比较；名额还会被和问句最像的一两家吃掉（覆盖垄断）。

结论：这类题换召回策略只能救一部分，正解是先 ETL 成宽表。

二、病根不在数据、也不在模型，在「哪些块能到答案面前」

第一层 · 覆盖垄断

全局排序按语义相似度取块，名额被和问句最像的那一两家吃掉。Q10 点名了两家公司，top-8 却只覆盖 1/15 家，top-40 也只有 2 家。

治法：按公司分层召回（每家各取几块），先把名额分配到公司。

第二层 · 字段错位

即使覆盖到了公司，含数字的块在该公司内部也排得很靠后——今世缘的营收金额块排到自家第 47 位，因为语义检索先命中「讨论收入的段落」，而不是那张数字表。

治法：用章节元数据路由，给「主要会计数据」这类章节保底名额。

召回策略（只换策略，不动数据、不动模型）	块数	覆盖	Q7	Q8	Q9	Q10	Q11	Q12
A 全局top-8	8	1/15	缺	半	够	半	缺	半
B 全局top-40	40	2/15	缺	半	够	半	缺	够
C 分层(15家×2)	30	15/15	缺	半	够	够	半	半
D 分层(15家×4)	60	15/15	缺	半	够	够	半	半
E 分层+关键章节保底	45	15/15	够	半	够	够	半	够

够＝证据齐全 半＝只齐一部分 缺＝一项都没有。Q7 谁增速最快 / Q8 谁亏损 / Q9 毛利率最高 / Q10 茅台vs五粮液 / Q11 三家营收谁高 / Q12 茅台三个数字。两种失败机制要分开治：加大 k（B，8→40 块）救不回 Q10 的覆盖垄断，按公司分层（C/D）才修好它；但 Q12 恰恰只要加大 k 就够了（B 即「够」，分层反而退回「半」）；Q7 最难，只有再叠加「主要会计数据」章节保底的元数据路由（E）才修好。代价是上下文从 8 块涨到 45 块；Q8 五种策略全程停在「半」（两家亏损公司只能召回一家）、Q11 只能从「缺」到「半」——这两题是真正的跨实体聚合，换召回策略解决不了。

三、结论：建库、微调、还是先做 ETL

什么样的问题	该怎么做	为什么（本实验的依据）
点名了公司、要某个具体数字或事实 「茅台营收多少」「洋河经销商几家」	建库（检索）	答案是原文里的一行：9/9 全部召回，最好第 1 位，还带得出处、可审计；年报年年换，库增量重建即可，不用重训
要稳定口径、术语、叙述方式 「用董秘的语气解释为什么下滑」	微调	这是不变的东西，检索给不了：它只能抄回原文，学不会「先讲行业、再讲公司、最后讲措施」这套组织方式
要跨实体聚合、排序、取极值 「15 家里谁增速最快」	两个都不对 先 ETL 成结构化宽表	检索按语义相似度取块，天生做不了全集扫描与极值比较：本次跨公司题在全局 top-8 下严格口径 0 道答对（唯一命中的 Q9 是碰巧）；靠分层 + 章节路由能救回一部分，但 Q8 全程只到「半」、Q11 从「缺」也只到「半」，且上下文要涨 5 倍。把 15 家的关键指标抽成一张宽表，再让模型读表，才是稳定解

四、四条诚实的注脚

① 我出的第一版标准答案自己就错了一题：Q8 只写了酒鬼酒，漏了亏得更多的顺鑫农业（-1.52 亿，顺鑫 2025 年报 P7 主要会计数据表），是回头翻原文才发现的——这反过来印证建库的意义：人对数字的记忆不可靠，检索到的原文才可靠。② 过程中修掉一个自己的实现缺陷：候选池大小原本跟着 top-k 变，导致同一个问题在 top-2 与 top-60 下排序不一致、分层召回取块不稳；改成固定取全部候选后结果才自洽（03_索引/检索.py）。③ 问答页面的大模型生成只是可选增强；本次评估的判定全部基于检索，不依赖任何大模型。④ 线上版原本走 Vercel 的 Python 后端，构建一直失败，最后改成纯静态：BM25 倒排索引压成 1.16MB 下发浏览器、正文按公司分片按需拉取，检索完全在浏览器里跑。自评 9/15 与本地严格口径持平，但不是同一批题——本地靠向量拿下的 Q1 在线上丢了，线上靠按公司分层补回了本地没救回的 Q10。代价是装不下神经向量，收益是手机流量也能直接打开：工程取舍，不是精度提升。

数据源：巨潮资讯网公开年报 PDF（15 家白酒上市公司 2025 年度报告） | 全部本地解析与检索，PDF 不进仓库 | 逐题记录见 05_评估/逐题记录.md，对照实验见 05_评估/对比_召回策略.md | 线上静态版自评见 10_Vercel/结果_前端版.json