同一批财报：什么问题该建库，什么问题该微调

方向 A · 白酒 15 家上市公司 2025 年报问答知识库 | 2,698 页 / 3,988 张表格 / 9,762 个文本块（每块带公司 · 章节 · 页码） | BM25 + bge-small-zh 向量混合检索 | 15 道题逐题记录 + 6 道失败题 × 5 种召回策略对照

一、15 道题的检索结果（判据：标准答案需要的证据——哪家公司 + 哪个数字——是否进 top-8）

题型分组	题数	检索可答	表现与原因
① 单公司 · 一个数字	9	9/9	答案就是原文里的一行：9 题全部召回，最好第 1 位命中，出处能精确到『公司 + 页码』
② 跨公司 · 全景（无候选集）	3	1/3	top-8 最多覆盖 8 家公司，『15 家里谁最…』结构上覆盖不全；唯一『对』的那题是碰巧——只覆盖 5/15 家就下『最高』结论
③ 跨公司 · 受限（给了候选集）	2	0/2	对照组：即使点名了公司也全错。Q10「茅台 vs 五粮液」top-8 只覆盖 1/15 家、top-40 也只有 2 家，名额被一家吃掉
④ 单公司 · 要拼多块	1	0/1	要 3 个数字（营收/净利/毛利率），top-8 被同一章节占满，只召回 1 个

合计 10/15 题检索可答（其中 1 题属碰巧，不算真会）。失败的 5 题全部与『哪些块能到答案面前』有关，但机制分两层，不止是『把 k 调大』能解决的——见下。

二、病根不在数据、也不在模型，在『哪些块能到答案面前』（两层）

第一层 覆盖垄断：全局排序按语义相似度取块，名额会被和问句最像的那一两家吃掉——Q10 点名了两家公司，top-8 只覆盖 1/15 家，top-40 也只有 2 家。第二层 字段错位：即使覆盖到了公司，含数字的块在该公司内部也排得很靠后（今世缘营收金额块排自家第 47 位），因为语义检索先命中『讨论收入的段落』，而不是数字表。下面只换召回策略，不动数据、不动模型权重：

召回策略	块数	覆盖	Q7	Q8	Q9	Q10	Q11	Q12
A 全局top-8	8	1/15	缺	半	够	半	缺	半
B 全局top-40	40	2/15	缺	半	够	半	缺	够
C 分层(15家×2)	30	15/15	缺	半	够	够	半	半
D 分层(15家×4)	60	15/15	缺	半	够	够	半	半
E 分层+关键章节保底	45	15/15	够	半	够	够	半	够

够＝证据齐全 半＝只齐一部分 缺＝一项都没有。Q7 谁增速最快 / Q8 谁亏损 / Q9 毛利率最高 / Q10 茅台vs五粮液 / Q11 三家营收谁高 / Q12 茅台三个数字。加大 k（B）救不回覆盖垄断；按公司分层（C/D）立刻修好 Q10；再叠加『主要会计数据』章节保底的元数据路由（E）才修好 Q7 与 Q12。代价是上下文从 8 块涨到 45 块；而 Q8、Q11 五种策略都没救回来——这两题是真正的『跨实体聚合』。

三、结论：建库、微调、还是先做 ETL

什么样的问题	该怎么做	为什么（本实验的依据）
点名了公司、要某个具体数字或事实 『茅台营收多少』『洋河经销商几家』	建库（检索）	答案是原文里的一行：9/9 全部召回，最好第 1 位，还带得出处、可审计；年报年年换，库增量重建即可，不用重训
要稳定口径、术语、叙述方式 『用董秘的语气解释为什么下滑』	微调	这是不变的东西，检索给不了：它只能抄回原文，学不会『先讲行业、再讲公司、最后讲措施』这套组织方式
要跨实体聚合、排序、取极值 『15 家里谁增速最快』	两个都不对 先 ETL 成结构化宽表	检索按语义相似度取块，天生做不了全集扫描与极值比较：本次 5 道跨公司题在全局 top-8 下只答对 1 道（还是碰巧）；靠分层 + 章节路由能救回一部分，但 Q8/Q11 五种策略都没救回，且上下文要涨 5 倍。把 15 家的关键指标抽成一张宽表，再让模型读表，才是稳定解

四、三条诚实的注脚

① 我出的第一版标准答案自己就错了一题：Q8 只写了酒鬼酒，漏了亏得更多的顺鑫农业（-1.52 亿，顺鑫 2025 年报 P7 主要会计数据表），是回头翻原文才发现的——这反过来印证建库的意义：人对数字的记忆不可靠，检索到的原文才可靠。② 过程中修掉一个自己的实现缺陷：候选池大小原本跟着 top-k 变，导致同一个问题在 top-2 与 top-60 下排序不一致、分层召回取块不稳；改成固定取全部候选后结果才自洽（03_索引/检索.py）。③ 问答页面的大模型生成只是可选增强；本次评估的判定全部基于检索，不依赖任何大模型。

数据源：巨潮资讯网公开年报 PDF（15 家白酒上市公司 2025 年度报告）| 全部本地解析与检索，PDF 不进仓库 | 逐题记录见 05_评估/逐题记录.md，对照实验见 05_评估/对比_召回策略.md